

Relatório final de Iniciação Científica

Processo 2024/07047-7

De 01/06/2024 a 31/05/2025

Fundação de Amparo à Pesquisa do Estado de São Paulo

Algoritmos off-the-shelf de Classificação e Regressão
Extrínseca

Orientador: Diego Furtado Silva

Candidato: Gabriel da Costa Merlin

Janeiro/2026



Orientador(a)



Orientando(a)

Resumo

Este relatório final descreve as atividades e resultados do projeto de Iniciação Científica FAPESP (Processo 2024/07047-7), desenvolvido de 01/06/2024 a 31/05/2025, cujo objetivo foi avaliar de forma sistemática o uso *off-the-shelf* de modelos de aprendizagem profunda em séries temporais, com foco em *Time Series Classification* (TSC) e *Time Series Extrinsic Regression* (TSER). Considerando a heterogeneidade dos dados e a menor padronização metodológica nessas tarefas, o estudo buscou evidenciar em quais cenários a reutilização direta ("*plug-and-play*") de arquiteturas consolidadas é suficiente e quando adaptações simples são necessárias para obter desempenho mais robusto.

A Fully Convolutional Network (FCN) foi adotada como arquitetura de referência e avaliada em sua forma base e em variações com mudanças isoladas na estrutura (tamanho dos filtros, número de filtros e profundidade). Os experimentos indicaram que a FCN padrão é competitiva, porém não domina consistentemente, e que ajustes pontuais podem reduzir o erro de forma relevante, especialmente em TSER. Uma análise mais robusta em TSER, com validação cruzada *10-fold* em 15 conjuntos, reforçou que a FCN base raramente apresenta o melhor desempenho e que variações simples podem diminuir o erro, ainda que os ganhos dependam das características do conjunto de dados. Para consolidar a comparação global, foi utilizado um Diagrama de Diferença Crítica com teste de Nemenyi, apontando pior ranqueamento médio para a FCN base e melhor desempenho agregado para a variação com filtros maiores.

Também foi investigada a substituição da cabeça de predição tradicional por Kolmogorov–Arnold Networks (KAN), avaliando uma versão híbrida (FCN pré-treinada + KAN) e uma versão fim a fim. Em larga escala (128 bases de TSC e 19 de TSER), a abordagem híbrida mostrou-se particularmente eficaz em TSC, enquanto em TSER os modelos temporais permaneceram competitivos e superiores a *baselines* não temporais, sem diferenças estatísticas marcantes entre variantes temporais. Os dados foram públicos e os códigos/resultados foram disponibilizados em repositórios abertos, culminando em publicação nos anais do ENIAC 2025.

1 Introdução

O avanço tecnológico das últimas décadas, impulsionado pela disseminação de sensores, dispositivos móveis, sistemas embarcados e serviços digitais, resultou em um crescimento expressivo de dados coletados ao longo do tempo [1]. Esses registros, organizados na forma de séries temporais, descrevem a evolução de fenômenos dinâmicos e aparecem de maneira recorrente em domínios como saúde, finanças, indústria, energia e monitoramento ambiental [2, 3, 4]. Nesse contexto, a análise eficiente de séries temporais tornou-se essencial para apoiar a tomada de decisão, identificar padrões e compreender tendências em cenários reais [5, 6].

Apesar de sua relevância, séries temporais historicamente recebem menor padronização quando comparadas a modalidades como texto e imagens [7, 8]. Enquanto áreas como processamento de linguagem natural e visão computacional contam com arquiteturas, pipelines e *benchmarks* consolidados, problemas temporais tendem a apresentar maior heterogeneidade, incluindo comprimentos variáveis, ruído, valores faltantes e diferenças de escala. Essa diversidade dificulta a adoção de soluções universais e contribui para a fragmentação de metodologias empregadas na literatura [9].

Dentre as principais tarefas em séries temporais destacam-se *forecasting*, *Time Series Classification* (TSC) e *Time Series Extrinsic Regression* (TSER). Enquanto o *forecasting* visa prever valores futuros da própria série e concentra grande parte da atenção da literatura, TSC e TSER buscam, respectivamente, atribuir uma classe discreta ou prever uma variável contínua externa a partir de uma série completa. Apesar de sua relevância em diversos domínios, essas duas tarefas recebem menor destaque, o que se reflete em um menor grau de padronização metodológica [10].

Como consequência, é comum que métodos competitivos em TSC e TSER sejam derivados de arquiteturas originalmente propostas para outros domínios, como visão computacional [11, 12]. Modelos profundos amplamente utilizados são frequentemente reaproveitados com modificações mínimas, favorecendo rapidez de implementação e baixo custo de desenvolvimento. No entanto, essa prática levanta uma questão central: até que ponto o uso direto, *off-the-shelf*, desses modelos é de fato eficaz e robusto em tarefas temporais, considerando a diversidade de conjuntos de dados e objetivos preditivos?

Este projeto investiga de forma sistemática a viabilidade do uso *off-the-shelf* de modelos amplamente empregados em TSC e TSER, avaliando seu desempenho quando utilizados de forma *plug-and-play*. O objetivo é analisar em quais cenários essa estratégia se mostra adequada e identificar situações em que adaptações arquiteturais

simples podem resultar em ganhos consistentes, mantendo a filosofia de reutilização e simplicidade. Assim, busca-se fornecer evidências experimentais sobre os limites e o potencial do uso *off-the-shelf* em tarefas de classificação e regressão extrínseca de séries temporais.

Este relatório está organizado da seguinte forma: a Seção 2 descreve as atividades desenvolvidas ao longo da vigência da Bolsa, incluindo os métodos empregados e os principais resultados obtidos. Ao final, é apresentada a publicação resultante desta Iniciação Científica.

2 Realizações do período

Durante o período de vigência da Bolsa, as atividades concentraram-se na avaliação sistemática do emprego de modelos *off-the-shelf* em tarefas de TSC e TSER, bem como na investigação de adaptações arquiteturais simples voltadas à melhoria de desempenho. Esta Seção está organizada da seguinte forma: a Subseção 2.1 apresenta os testes iniciais realizados para validação dos modelos; a Subseção 2.2 discute a comparação sistemática entre as modificações arquiteturais avaliadas; a Subseção 2.3 trata da troca da cabeça de predição, com ênfase na substituição do classificador Multi-Layer Perceptron (MLP) por abordagens baseadas em Kolmogorov-Arnold Networks (KAN); e a Subseção 2.4 descreve os procedimentos adotados para a gestão dos dados e códigos utilizados nos experimentos. Por fim, a Subseção 2.5 apresenta as conclusões do período, sintetizando os principais resultados obtidos e suas implicações.

2.1 Testes iniciais

Com o objetivo de iniciar a verificação da validade do uso de modelos *off-the-shelf* em tarefas de séries temporais, tornou-se necessário conduzir experimentos baseados em modificações arquiteturais controladas. Para esse fim, foi escolhida a *Fully Convolutional Network* (FCN) [9] como ponto de partida. Essa escolha se justifica pelo fato de a FCN ser uma arquitetura amplamente utilizada, originalmente proposta no contexto de visão computacional, mas que apresenta resultados competitivos em tarefas de TSC e TSER [10]. Além disso, trata-se de um modelo computacionalmente eficiente quando comparado a arquiteturas com desempenho semelhante ou superior, como aquelas baseadas em Transformers [13].

A FCN base adotada neste trabalho é composta por três camadas convolucionais, contendo, respectivamente, 128 filtros de tamanho 8, 256 filtros de tamanho 5 e 128

filtros de tamanho 3, conforme ilustrado na Figura 1. A partir dessa arquitetura base, foram propostas três modificações, cada uma alterando um aspecto específico do modelo. A variação *FCN_biggerKernels* aumenta o tamanho dos filtros para 12, 8 e 5, respectivamente; a *FCN_moreKernels* eleva o número de filtros para 256, 512 e 256; e a *FCN_moreLayers* adiciona duas novas camadas convolucionais, sendo a primeira composta por 256 filtros de tamanho 5 e a segunda por 128 filtros de tamanho 3.




Figura 1: Arquitetura da Fully Convolutional Network (FCN) base. Adaptada de [9]

Após a definição dos modelos, foram selecionados conjuntos de dados dos *benchmarks* de TSC [14] e TSER [15] com base em sua diversidade. Buscou-se incluir conjuntos grandes e pequenos, séries univariadas e multivariadas, bem como séries de diferentes comprimentos, de modo a avaliar o comportamento dos modelos em cenários variados. Foi aplicada normalização z-score por canal, com média e desvio padrão calculados no conjunto de treino e aplicados ao teste. Cada modelo foi treinado cinco vezes em cada conjunto de dados, por 1000 épocas, com taxa de aprendizado de 0,001 e critério de *early stopping* com paciência de 20 épocas. Os resultados obtidos são apresentados nas Tabelas 1 e 2, reportando-se a média e o desvio padrão das métricas de desempenho.

Tabela 1: Resultados de TSC reportados em termos de acurácia (média $\pm$ desvio padrão) para a FCN base e suas variações arquiteturais. Os valores em negrito indicam o melhor desempenho observado para cada conjunto de dados.

Dataset	FCN	biggerKernels	moreKernels	moreLayers
ArrowHead	0.56 ± 0.15	0.41 ± 0.06	0.39 ± 0.16	0.37 ± 0.09
OSULeaf	0.87 ± 0.11	0.82 ± 0.07	0.85 ± 0.07	0.90 ± 0.08
NATOPS	0.91 ± 0.02	0.90 ± 0.03	0.91 ± 0.02	0.85 ± 0.11
Epilepsy	0.97 ± 0.00	0.97 ± 0.00	0.97 ± 0.00	0.97 ± 0.00
Haptics	0.32 ± 0.06	0.32 ± 0.07	0.34 ± 0.05	0.43 ± 0.08

A análise dos resultados indica que, embora a FCN base apresente desempenho competitivo em diversos cenários, ela não é consistentemente superior às suas variações em todos os conjuntos de dados. Em algumas situações, modificações simples na

Tabela 2: Resultados de TSER reportados em termos de Erro Quadrático Médio (RMSE; média $\pm$ desvio padrão) para a FCN base e suas variações arquiteturais. Os valores em negrito correspondem ao melhor desempenho (menor erro) observado para cada conjunto de dados.

Covid3Month	0.07 ± 0.02	0.08 ± 0.03	0.05 ± 0.00	0.07 ± 0.01
FloodM1	0.02 ± 0.01	0.01 ± 0.01	0.01 ± 0.00	0.01 ± 0.00
AppliancesEn	13.14 ± 6.58	9.02 ± 3.46	9.80 ± 2.33	8.44 ± 3.29
HouseholdPC2	131.17 ± 98.03	172.68 ± 80.42	184.20 ± 182.76	237.41 ± 204.53
IEEEPPG	36.45 ± 5.15	34.52 ± 4.42	33.04 ± 2.09	28.17 ± 1.93

arquitetura resultaram em melhorias relevantes, enquanto em outras não houve ganhos significativos. Esses achados reforçam as limitações do uso indiscriminado de modelos *off-the-shelf*, evidenciando que pequenas alterações arquiteturais podem ser necessárias para alcançar melhor desempenho em determinados contextos.

Observa-se ainda que, nos conjuntos de TSC avaliados, as acurácias obtidas são frequentemente elevadas, o que pode indicar menor dificuldade relativa dessas tarefas para os modelos considerados ou até uma saturação de desempenho nos conjuntos analisados. Em contrapartida, nos experimentos de TSER, as diferenças entre as arquiteturas são mais pronunciadas, sugerindo maior sensibilidade a modificações estruturais. Por esse motivo, os experimentos mais extensivos passaram a focar em TSER, onde os desafios são mais evidentes e o impacto das adaptações arquiteturais tende a ser mais informativo.

2.2 Comparação das modificações

Conforme discutido na Seção 2.1, os experimentos subsequentes foram conduzidos exclusivamente com conjuntos de dados da tarefa de TSER. Dentre os conjuntos disponíveis no *benchmark*, quatro não foram considerados devido ao seu elevado tamanho e à dificuldade de execução do modelo mais complexo (*FCN_moreLayers*) em placas de vídeo com capacidade limitada de memória (foi usado uma RTX 3060 de 12GB de VRAM compartilhada com outros alunos de Iniciação Científica), a saber: *BIDMCHR*, *BIDMCRR*, *BIDMCSpO2* e *FloodModeling3*. Dessa forma, os experimentos foram realizados nos 15 conjuntos restantes.

Com o objetivo de obter uma avaliação mais robusta e estável do desempenho dos modelos, o fluxo de treinamento foi aprimorado, passando a incorporar validação cruzada [16] com 10 partições (*10-fold cross-validation*) em todo o dado (também normalizados por canal para cada *fold* no treino e aplicado ao teste), não havendo

partição de teste final. Em cada *fold*, os modelos foram treinados por até 2000 épocas, utilizando taxa de aprendizado de 0,01 e critério de *early stopping* com paciência de 100 épocas. Os resultados obtidos sob essa configuração são apresentados na Tabela 3.

Tabela 3: Resultados de TSER em termos de RMSE final (média $\pm$ desvio padrão) para a FCN base e suas variações arquiteturais. O melhor desempenho (menor RMSE) em cada conjunto de dados é destacado em negrito.

Dataset	FCN	biggerKernels	moreKernels	moreLayers
PPGDalia	11.34 $\pm$ 0.13	10.33 $\pm$ 0.12	10.46 $\pm$ 0.16	8.77 $\pm$ 0.14
AustraliaR	12.94 $\pm$ 12.70	12.93 $\pm$ 12.72	12.95 $\pm$ 12.71	13.00 $\pm$ 12.69
LiveFuelMC	41.25 $\pm$ 1.78	41.18 $\pm$ 1.42	41.16 $\pm$ 1.62	41.20 $\pm$ 1.55
AppliancesEn	3.19 $\pm$ 0.56	3.01 $\pm$ 0.59	3.10 $\pm$ 0.70	3.19 $\pm$ 0.73
Covid3Month	0.047 $\pm$ 0.005	0.045 $\pm$ 0.005	0.046 $\pm$ 0.004	0.046 $\pm$ 0.005
BenzeneConc	0.83 $\pm$ 0.10	0.66 $\pm$ 0.08	0.79 $\pm$ 0.11	0.50 $\pm$ 0.08
IEEEPPG	5.17 $\pm$ 0.59	4.62 $\pm$ 0.38	4.83 $\pm$ 0.42	4.12 $\pm$ 0.54
HouseholdPC1	161.17 $\pm$ 52.63	158.25 $\pm$ 46.92	162.63 $\pm$ 48.73	162.50 $\pm$ 44.50
HouseholdPC2	32.22 $\pm$ 2.93	31.83 $\pm$ 2.84	32.08 $\pm$ 2.88	32.97 $\pm$ 2.41
BeijingPM10Q	79.71 $\pm$ 3.19	78.43 $\pm$ 3.42	78.22 $\pm$ 2.50	75.16 $\pm$ 3.58
BeijingPM25Q	57.10 $\pm$ 2.42	55.37 $\pm$ 2.26	56.14 $\pm$ 2.33	51.75 $\pm$ 2.05
FloodM1	0.017 $\pm$ 0.004	0.017 $\pm$ 0.004	0.017 $\pm$ 0.005	0.017 $\pm$ 0.004
FloodM2	0.010 $\pm$ 0.003	0.011 $\pm$ 0.003	0.0096 $\pm$ 0.0032	0.010 $\pm$ 0.005
NewsHeadlineS	0.142 $\pm$ 0.001	0.142 $\pm$ 0.001	0.142 $\pm$ 0.001	0.142 $\pm$ 0.001
NewsTitleS	0.137 $\pm$ 0.001	0.137 $\pm$ 0.002	0.137 $\pm$ 0.002	0.137 $\pm$ 0.002

A análise dos resultados indica que a FCN base raramente apresenta o melhor desempenho entre as arquiteturas avaliadas. Em particular, o modelo padrão supera suas variações em apenas um dos conjuntos de dados considerados, enquanto modificações arquiteturais simples levam a melhorias consistentes em diversos cenários.

Esses resultados fornecem fortes indícios de que o uso direto de modelos *off-the-shelf*, sem qualquer adaptação à tarefa ou às características dos dados, pode levar a desempenhos subótimos. Além disso, a variabilidade observada entre os conjuntos de dados sugere que não existe uma única modificação arquitetural universalmente superior, mas sim configurações que se mostram mais adequadas a determinadas propriedades dos dados, como escala, nível de ruído e dinâmica temporal.

Para complementar a análise individual por conjunto de dados, o desempenho global das arquiteturas foi avaliado por meio do Diagrama de Diferença Crítica [17], apresentado na Figura 2. Esse procedimento permite comparar os modelos de forma agregada, considerando o ranqueamento médio de cada arquitetura ao longo de todos os conjuntos avaliados, bem como verificar a significância estatística das diferenças observadas por meio do teste de Nemenyi.




Figura 2: Diagrama de Diferença Crítica. A linha preta horizontal indica grupos de modelos que não possuem diferença estatisticamente significativa (quanto mais perto de 1, melhor).

A partir do diagrama, observa-se que a FCN base apresenta o pior ranqueamento médio em comparação às suas variações, enquanto a configuração *biggerKernels* obtém o melhor desempenho global, ainda que as diferenças entre as arquiteturas não sejam estatisticamente significativas. Esse resultado reforça que, mesmo entre modificações arquiteturais simples, existem alternativas mais adequadas do que a FCN padrão para tarefas de TSER.

Ressalta-se que as arquiteturas avaliadas representam apenas um subconjunto do espaço de possíveis modificações. Ainda assim, os resultados obtidos apontam para a relevância de investigações futuras envolvendo estratégias de meta-aprendizado, capazes de adaptar automaticamente modelos *off-the-shelf* às características específicas dos dados. Abordagens desse tipo podem selecionar ou ajustar a arquitetura mais apropriada para cada conjunto, conciliando simplicidade com ganhos mais consistentes de desempenho.

2.3 Troca da cabeça de predição

Os experimentos anteriores concentraram-se em investigar se modificações nas camadas convolucionais da FCN, isto é, nas camadas responsáveis pela extração de características temporais, seriam capazes de produzir melhores modelagens. No entanto, um componente igualmente relevante da arquitetura permaneceu inalterado até então: a cabeça de decisão ao final da rede, que pode atuar tanto como classificador, no caso de TSC, quanto como regressor, em TSER. Na FCN original, essa cabeça é composta por uma única camada Linear, a qual pode ser interpretada como uma forma simplificada de uma MLP, uma vez que consiste apenas em um conjunto de perceptrons com pesos treináveis e funções de ativação fixas.

Em consonância com essa motivação, no final de 2024 foi proposta a *Kolmogorov-Arnold Network* (KAN) [18], que surge como uma alternativa às MLPs tradicionais. Enquanto as MLPs utilizam funções de ativação fixas e aprendem apenas os pesos das conexões, as KANs adotam a estratégia inversa: os pesos são fixados e as funções de ativação são aprendidas por meio de *splines*. Além disso, no domínio temporal, ambas compartilham uma característica importante: não são temporalmente conscientes, no sentido de que todos os pontos de entrada são considerados de forma global, sem incorporar vieses indutivos específicos para séries temporais, como ocorre nas convoluções. Diante disso, tornou-se natural investigar a substituição da MLP por uma KAN como cabeça preditora da FCN.

A partir dessa proposta, foram desenvolvidas duas novas arquiteturas, denominadas Hybrid FCN-KAN e *FCKAN*, esta última ilustrada na Figura 3. Ambas mantêm o bloco convolucional da FCN como extrator de características e utilizam uma KAN como cabeça de predição. A principal diferença entre elas reside na estratégia de treinamento: na arquitetura FCKAN, as camadas convolucionais e a KAN são treinadas de forma conjunta, permitindo que o extrator aprenda representações otimizadas especificamente para a KAN; por outro lado, na Hybrid FCN-KAN, uma FCN base é inicialmente treinada até a convergência, e apenas posteriormente a cabeça MLP é substituída por uma KAN, que é treinada mantendo o corpo convolucional congelado.




Figura 3: Comparação entre as arquiteturas FCN e FCKAN: a FCKAN substitui a camada de decisão baseada em MLP da FCN por um módulo KAN.

Como esse conjunto de experimentos envolveu um número reduzido de modelos, além de arquiteturas mais leves quando comparadas às variações estruturais da FCN, foi possível avaliá-los em todos os conjuntos de dados disponíveis: 128 bases de TSC e 19 bases de TSER, sendo cada um dos *datasets* normalizados por canal. Em ambas as tarefas, a MLP foi treinada por 100 épocas utilizando o otimizador Adam, com taxa de aprendizado de 1×10^{-3} , enquanto a FCN foi treinada por 2000 épocas sob as mesmas configurações de otimização. A KAN foi implementada por meio da biblioteca PyKAN¹, baseada em CPU e disponibilizada no GitHub¹, utilizando o otimizador L-BFGS, com 100 etapas de otimização. A arquitetura adotada possui duas camadas ocultas com 40 unidades cada ($[40, 40]$), tamanho de grade igual a 5 e ordem polinomial (**korder**) igual a 3. Os resultados obtidos para TSC são apresentados na Figura 4, enquanto os resultados para TSER encontram-se na Figura 5.




Figura 4: Diagrama de Diferença Crítica para TSC. A barra horizontal preta indica grupos de modelos sem diferença estatisticamente significativa (quanto mais próximo de **1**, melhor).

Os experimentos realizados indicam que, para TSC, a arquitetura Hybrid FCN-KAN apresentou desempenho superior às FCNs tradicionais e aos demais baselines. Esse resultado sugere que o pré-treinamento de uma FCN para extração de características temporais, seguido da aplicação de uma KAN como cabeça preditora, traz benefícios relevantes. A arquitetura FCKAN, treinada de forma fim a fim, apresentou desempenho estatisticamente comparável, mas não superou consistentemente o modelo híbrido, possivelmente em função das maiores dificuldades de otimização decorrentes do treinamento conjunto. Ainda assim, ambas as propostas superaram modelos sem viés temporal explícito, reforçando a importância de incorporar estruturas adequadas ao domínio temporal.

¹<https://github.com/KindXiaoming/pykan>




Figura 5: Diagrama de Diferença Crítica para TSER. A barra horizontal preta indica grupos de modelos sem diferença estatisticamente significativa (quanto mais próximo de 1, melhor).

No caso de TSER, a extração de características temporais também se mostrou fundamental. Embora a FCN tenha obtido a melhor colocação média, os testes estatísticos não identificaram diferenças significativas entre os modelos avaliados. Ainda assim, modelos com componentes temporais (FCN, Hybrid FCN-KAN e FCKAN) apresentaram desempenho consistentemente superior aos baselines não temporais, corroborando a relevância de capturar dinâmicas temporais. Embora as integrações com KAN não tenham superado estatisticamente a FCN nessa tarefa, seus resultados competitivos indicam potencial, especialmente considerando possíveis ajustes adicionais voltados especificamente para regressão.

Como os resultados obtidos nesses experimentos mostraram-se promissores, eles serviram de base para a elaboração de um artigo submetido e aceito no Encontro Nacional de Inteligência Artificial e Computacional (ENIAC 2025). O trabalho encontra-se publicado nos anais do evento², onde são apresentados em maior nível de detalhe os aspectos de implementação, bem como análises e discussões complementares aos resultados aqui reportados.

2.4 Gestão dos dados

Os dados utilizados neste projeto são integralmente de acesso público. Os conjuntos de TSC estão disponíveis no repositório da UCR³, enquanto os conjuntos de TSER encontram-se em um repositório específico⁴. Ambos podem ser facilmente acessados

²<https://sol.sbc.org.br/index.php/eniac/article/view/38846>

³https://www.cs.ucr.edu/~eamonn/time_series_data_2018/

⁴<http://tseregression.org/>

por meio da biblioteca Python Aeon [19], que fornece interfaces padronizadas para o carregamento e a manipulação de séries temporais.

Os conjuntos de dados não foram armazenados localmente de forma permanente, sendo obtidos automaticamente a cada execução dos experimentos e removidos ao final do processo. Essa estratégia assegura reprodutibilidade e reduz a dependência de armazenamento local, garantindo o uso das versões oficiais dos dados.

Todos os códigos-fonte e resultados obtidos ao longo da Iniciação Científica estão disponibilizados publicamente no GitHub. Os materiais relacionados ao artigo discutido na Subseção 2.3 encontram-se em um repositório dedicado⁵, enquanto os códigos das demais etapas do projeto estão organizados em um repositório separado⁶.

2.5 Conclusão

Ao longo da vigência da bolsa, este projeto investigou de forma sistemática o uso de modelos *off-the-shelf* em tarefas de classificação e regressão de séries temporais, com foco na FCN e em adaptações arquiteturais simples. Os experimentos indicaram que, embora a FCN padrão apresente desempenho competitivo, modificações pontuais em sua estrutura, como ajustes nos filtros, aumento de profundidade ou substituição da cabeça de predição, podem gerar ganhos consistentes, especialmente em cenários mais desafiadores, como os conjuntos de TSER. A análise de arquiteturas híbridas com KANs também evidenciou benefícios na separação entre extração temporal de características e modelagem não linear da saída.

De modo geral, os resultados obtidos sugerem que o uso indiscriminado de modelos *off-the-shelf* pode levar a soluções subótimas, enquanto adaptações relativamente simples já são capazes de melhorar o desempenho. Embora estratégias de meta-aprendizado não tenham sido exploradas, em função do esforço necessário para a consolidação dos experimentos e a redação de um artigo científico, o trabalho resultou na publicação do primeiro artigo do aluno como primeiro autor, aceito no ENIAC 2025. Os achados deste projeto estabelecem uma base sólida para investigações futuras, incluindo abordagens de meta-aprendizado como continuidade natural desta pesquisa.

⁵<https://github.com/gabrielcmerlin/FCKAN>

⁶<https://github.com/gabrielcmerlin/models-off-the-shelf>

Publicações resultantes da Bolsa

- **FCKAN: Evaluating KAN for Time Series Classification and Extrinsic Regression.** Trabalho apresentado em conferência nacional: *Encontro Nacional de Inteligência Artificial e Computacional (ENIAC 2025)*, na trilha voltada a alunos de graduação. Publicado nos anais do evento. O trabalho é resultado das atividades desenvolvidas no âmbito da presente Bolsa de Iniciação Científica. Disponível em: <https://sol.sbc.org.br/index.php/eniac/article/view/38846>.

FCKAN: Evaluating KAN for Time Series Classification and Extrinsic Regression

Gabriel da Costa Merlin¹, Adilson Junior Alves Medronha¹, Diego Furtado Silva¹

¹Institute of Mathematical and Computer Sciences, University of São Paulo
São Carlos, São Paulo, Brazil

{gabrielcmerlin, adilson.medronha, diegofsilva}@usp.br

Abstract. *Time Series Classification (TSC) and Time Series Extrinsic Regression (TSER) are critical tasks across diverse fields. While Fully Convolutional Networks (FCNs) effectively capture temporal dependencies, Kolmogorov–Arnold Networks (KANs) offer greater flexibility and interpretability. However, integrating KANs with temporal encoders and their application to regression tasks remain largely unexplored. This paper introduces FCKAN and Hybrid FCN-KAN, two novel architectures that combine FCNs and KANs for TSC and TSER. The first is an end-to-end model, while the second is a hybrid approach that leverages a pre-trained FCN as a feature extractor followed by a KAN. We conduct experiments on 147 benchmark datasets. For TSC, both architectures outperform non-temporal baselines and achieve competitive performance with FCNs. In TSER, although all models are statistically equivalent, temporal models consistently outperform non-temporal baselines.*

1. Introduction

Time Series Classification (TSC) and Time Series Extrinsic Regression (TSER) are essential tasks in various domains, including healthcare, finance, and engineering [Ismail Fawaz et al. 2019, Tan et al. 2021a]. Recent advances in deep learning strategies, particularly convolutional architectures such as Fully Convolutional Networks (FCNs), have shown strong performance by extracting temporal features directly from raw input. Kolmogorov–Arnold Networks (KANs) is a newly proposed model class that replaces scalar weights with learnable spline functions, offering improved flexibility and interpretability over traditional Multilayer Perceptron (MLP). While promising results have been demonstrated on classification benchmarks, KANs remain relatively unexplored in conjunction with robust temporal encoders for TSC and TSER tasks, which is particularly interesting, given that KANs do not possess intrinsic spatial or temporal awareness.

This paper proposes FCKAN¹, a novel architecture that integrates FCNs and KANs in a unified end-to-end framework for both TSC and TSER. We also introduce Hybrid FCN-KAN, a hybrid two-stage variant in which a pre-trained FCN serves as a temporal feature extractor for a downstream KAN. Our experiments on diverse benchmark datasets aim to evaluate the robustness and overall effectiveness of combining convolutional encoders with spline-based function approximators, thereby bridging the gap between high-capacity feature extraction and interpretable modeling.

¹<https://github.com/gabrielcmerlin/FCKAN>

Referências

- [1] B. Data, “The next frontier for innovation, competition, and productivity,” 2011.
- [2] B. Pyakillya, N. Kazachenko, and N. Mikhailovsky, “Deep learning for ecg classification,” *Journal of Physics: Conference Series*, vol. 913, p. 012004, oct 2017.
- [3] P. Rousseeuw, D. Perrotta, M. Riani, and M. Hubert, “Robust monitoring of time series with application to fraud detection,” *Econometrics and statistics*, vol. 9, pp. 108–121, 2019.
- [4] C.-C. Wang, Y. Kang, P.-C. Shen, Y.-P. Chang, and Y.-L. Chung, “Applications of fault diagnosis in rotating machinery by using time series analysis with neural network,” *Expert Systems with Applications*, vol. 37, no. 2, pp. 1696–1702, 2010.
- [5] E. Keogh, “Time series data mining: A unifying view,” in *2024 IEEE 11th International Conference on Data Science and Advanced Analytics (DSAA)*, pp. 1–3, IEEE, 2024.
- [6] C.-C. M. Yeh, Y. Zhu, L. Ulanova, N. Begum, Y. Ding, H. A. Dau, Z. Zimmerman, D. F. Silva, A. Mueen, and E. Keogh, “Time series joins, motifs, discords and shapelets: a unifying view that exploits the matrix profile,” *Data Mining and Knowledge Discovery*, vol. 32, no. 1, pp. 83–123, 2018.
- [7] A. Bagnall, J. Lines, A. Bostrom, J. Large, and E. Keogh, “The great time series classification bake off: a review and experimental evaluation of recent algorithmic advances,” *Data mining and knowledge discovery*, vol. 31, no. 3, pp. 606–660, 2017.
- [8] B. D. Fulcher, M. A. Little, and N. S. Jones, “Highly comparative time-series analysis: the empirical structure of time series and their methods,” *Journal of the Royal Society Interface*, vol. 10, no. 83, p. 20130048, 2013.
- [9] Z. Wang, W. Yan, and T. Oates, “Time series classification from scratch with deep neural networks: A strong baseline,” in *2017 International joint conference on neural networks (IJCNN)*, pp. 1578–1585, IEEE, 2017.
- [10] H. Ismail Fawaz, G. Forestier, J. Weber, L. Idoumghar, and P.-A. Muller, “Deep learning for time series classification: a review,” *Data mining and knowledge discovery*, vol. 33, no. 4, pp. 917–963, 2019.

- [11] H. Ismail Fawaz, B. Lucas, G. Forestier, C. Pelletier, D. F. Schmidt, J. Weber, G. I. Webb, L. Idoumghar, P.-A. Muller, and F. Petitjean, “Inceptiontime: Finding alexnet for time series classification,” *Data Mining and Knowledge Discovery*, vol. 34, no. 6, pp. 1936–1962, 2020.
- [12] F. Karim, S. Majumdar, H. Darabi, and S. Chen, “Lstm fully convolutional networks for time series classification,” *IEEE access*, vol. 6, pp. 1662–1669, 2017.
- [13] G. Zerveas, S. Jayaraman, D. Patel, A. Bhamidipaty, and C. Eickhoff, “A transformer-based framework for multivariate time series representation learning,” in *Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining*, pp. 2114–2124, 2021.
- [14] A. Bagnall, H. A. Dau, J. Lines, M. Flynn, J. Large, A. Bostrom, P. Southam, and E. Keogh, “The uea multivariate time series classification archive, 2018,” *arXiv preprint arXiv:1811.00075*, 2018.
- [15] C. W. Tan, C. Bergmeir, F. Petitjean, and G. I. Webb, “Monash university, uea, ucr time series extrinsic regression archive,” *arXiv preprint arXiv:2006.10996*, 2020.
- [16] R. Kohavi *et al.*, “A study of cross-validation and bootstrap for accuracy estimation and model selection,” in *Ijcai*, vol. 14, pp. 1137–1145, Montreal, Canada, 1995.
- [17] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” *Journal of Machine learning research*, vol. 7, no. Jan, pp. 1–30, 2006.
- [18] Z. Liu, Y. Wang, S. Vaidya, F. Ruehle, J. Halverson, M. Soljačić, T. Y. Hou, and M. Tegmark, “Kan: Kolmogorov-arnold networks,” *arXiv preprint arXiv:2404.19756*, 2024.
- [19] M. Middlehurst, A. Ismail-Fawaz, A. Guillaume, C. Holder, D. Guijo-Rubio, G. Bulatova, L. Tsaprounis, L. Mentel, M. Walter, P. Schäfer, *et al.*, “aeon: a python toolkit for learning from time series,” *Journal of Machine Learning Research*, vol. 25, no. 289, pp. 1–10, 2024.